

Тестовое задание для кандидата

1. Описание задачи

Необходимо автоматически извлекать перечни: сокращения; термины и определения из документов. Документы изначально без текстового слоя (pdf из картинок - сканы документов)

Необходимо извлекать перечни в postgresSQL, связь с документом, чтобы была возможность получить перечни по названию документа.

2. Особенности документов

- Разнородное качество сканов
- Возможное отсутствие искомых разделов
- Расположение разделов в произвольных местах документа (начало, середина)

3. Стэк и ограничения

При использовании технологий, работающих на GPU, необходимо учитывать ограничение - 32Гб видеопамяти. Решение необходимо обернуть в Docker.

4. Отказоустойчивость и возможность рестарта

- При перезапуске сервиса или возникновении ошибок система должна продолжать обработку с учётом уже обработанных документов.
- Оптимизация по уже обработанным данным (избежание повторной обработки).